

# Classification spatio-temporelle des dégâts causés par les inondations à partir d'images satellites par Deep Learning Explicable (XAI) et MLOps

---

## Chapitre 1 — Contexte général du projet

### 1.1 Introduction

Dans un contexte où les catastrophes naturelles s'intensifient à l'échelle mondiale, **l'évaluation automatique des dégâts causés aux bâtiments** (Building Damage Assessment, BDA) constitue l'un des défis opérationnels les plus pressants de la gestion post-catastrophe. Rapidement conduite et fiable, une telle évaluation permet **d'orienter les secours, d'estimer les pertes et de planifier la reconstruction dans la fenêtre critique qui suit immédiatement un événement**. Or, les méthodes actuelles manuelles ou semi-automatiques peinent à répondre aux exigences de rapidité, de scalabilité et de fiabilité que cette opération requiert.

L'essor du Deep Learning appliqué à l'imagerie satellite a ouvert des perspectives prometteuses pour automatiser cette tâche. Cependant, les solutions existantes souffrent d'un déficit structurel qui limite leur utilité opérationnelle réelle : elles produisent des prédictions sans les expliquer, dans des conditions expérimentales difficilement reproductibles, sans pipeline de déploiement ni mécanisme de suivi en production. En d'autres termes, ces modèles sont *performants en laboratoire*, mais *non déployables en opérations réelles*.

Ce chapitre présente le cadre général dans lequel s'inscrit ce projet de fin d'études. Il expose les enjeux de l'évaluation des dégâts bâtiments, analyse les limites des solutions existantes, introduit le contexte marocain comme terrain de motivation, et formule la problématique ainsi que les objectifs du projet. L'ambition centrale est de développer non pas un simple modèle de classification, mais un **système industrialisé, explicable et reproductible** une première brique opérationnelle conçue pour être adaptée à de nouveaux contextes géographiques dans des travaux ultérieurs.

### 1.2 Enjeux de l'évaluation des dégâts bâtiments : une opération critique sous contrainte de temps

#### 1.2.1 Les inondations : première cause de dommages aux infrastructures bâties

Les inondations représentent, à l'échelle mondiale, la catégorie de catastrophes naturelles la plus fréquente et la plus destructrice pour les infrastructures bâties. Elles

constituent entre **35 % et 40 %** de l'ensemble des catastrophes météorologiques répertoriées. La population mondiale exposée aux crues a progressé de près de **25 % entre 1970 et 2020**, et les pertes économiques annuelles moyennes associées atteignent **388 milliards USD par an** à l'échelle mondiale une trajectoire que les projections climatiques du GIEC placent en hausse structurelle (UNDRR, GAR 2025). Le tableau suivant synthétise les principaux indicateurs de cette tendance longue :

| Indicateur                                        | Valeur                    | Période            | Source                          |
|---------------------------------------------------|---------------------------|--------------------|---------------------------------|
| Part des inondations parmi les catastrophes météo | 35 – 40 %                 | Tendance longue    | UNDRR, GAR 2025                 |
| Population mondiale exposée aux crues             | +24,9 % (28→35 M)         | 1970–2020          | UNDRR, GAR 2025                 |
| Pertes économiques annuelles moyennes             | 388 Mrd USD/an            | Projection globale | UNDRR, GAR 2025                 |
| Dommages assurés – inondations                    | 98,2 Mrd USD              | 2013–2023          | Munich Re / Statista, 2024      |
| Intensification des crues – Afrique du Nord       | ×2 prob. / +10% intensité | Tendance récente   | World Weather Attribution, 2025 |

Tableau 1.1 — Indicateurs statistiques mondiaux liés aux inondations

### 1.2.2 Le Building Damage Assessment : une opération sous contrainte opérationnelle sévère

**L'évaluation des dégâts sur les bâtiments (BDA)** est définie par les protocoles opérationnels internationaux FEMA, Copernicus Emergency Management Service, UNOSAT comme l'une des premières opérations à conduire après une catastrophe. Son objectif est de produire, idéalement dans une fenêtre de **24 à 72 heures** après l'événement, une cartographie exhaustive de l'état des bâtiments affectés, structurée selon des classes de sévérité standardisées. Ces cartes alimentent directement les décisions d'allocation des secours, les estimations de pertes pour les assureurs et les gouvernements, ainsi que la planification de la reconstruction.

Comme cité dans DeepDamageNet (arXiv, 2024) : « *In addition to providing information to first responders for rescue operations and relief efforts, [BDA] also provides useful information for local government and related organizations for the estimation of economic loss and damage distribution in the subsequent reconstruction and recovery phase.* »

La contrainte de temps est déterminante : lorsque les zones affectées s'étendent sur des milliers de kilomètres carrés comme ce fut le cas lors des crues du Gharb au Maroc en 2026 l'inspection manuelle des bâtiments devient *structurellement impossible* dans la fenêtre requise. Seule une approche automatisée et scalable, s'appuyant sur l'imagerie satellite et l'intelligence artificielle, peut répondre à cette exigence.

### 1.3 Étude de l'existant : méthodes actuelles et leurs limites

#### 1.3.1 Évolution des méthodes d'évaluation des dégâts bâtiments

L'évaluation des dégâts bâtiments a traversé plusieurs générations méthodologiques, chacune apportant des améliorations en termes d'automatisation et de couverture, tout en introduisant de nouvelles limitations.

**Première génération :** L'inspection terrain manuelle historiquement dominante, cette méthode consiste à envoyer des experts inspecter les bâtiments un à un. Si elle offre une précision individuelle élevée, elle est documentée dans la littérature comme **slow, expensive, and dangerous** à grande échelle (DeepDamageNet, arXiv 2024 ., PMC 2023). Le séisme d'Haïti en 2010 constitue un cas d'école : l'évaluation de 30 000 bâtiments autour de Port-au-Prince a nécessité l'équivalent d'une année-personne de travail bénévole (World Bank / ImageCat, 2010). Cette méthode est aujourd'hui inadaptée aux catastrophes de grande ampleur.

**Deuxième génération :** La photo-interprétation manuelle sur images satellite VHR, l'avènement des images satellite à très haute résolution (VHR, résolution  $\leq 50$  cm) a permis d'étendre la couverture sans déplacer d'équipes terrain. Toutefois, cette approche reste dépendante de la subjectivité des interprètes, est non reproductible et ne peut être conduite en temps réel. Elle ne génère aucune traçabilité des décisions prises.

**Troisième génération :** Le Deep Learning sur images satellite ,la publication du dataset *xBD* et l'organisation du challenge *xView2* ont catalysé une vague de recherche appliquant le Deep Learning à la classification automatique des dégâts bâtiments en 4 classes. Ces approches offrent vitesse et scalabilité. Cependant, comme le montrera l'analyse qui suit, elles souffrent d'un triple déficit structurel opacité, absence d'industrialisation, absence de reproductibilité qui en limite la portée opérationnelle réelle.

#### 1.3.2 Comparaison des approches : du manuel à l'automatisé

| Méthode                                     | Délai          | Couverture              | Niveau d'automatisation    |
|---------------------------------------------|----------------|-------------------------|----------------------------|
| Inspection terrain manuelle                 | Semaines       | Zones accessibles       | Aucune                     |
| Photo-interprétation manuelle (images VHR)  | Jours–semaines | Large mais partielle    | Faible                     |
| Machine Learning classique (SVM, RF)        | Heures–jours   | Large, automatisable    | Partielle                  |
| Deep Learning (état de l'art) — boîte noire | Minutes–heures | Très large, automatisée | Expérimentale uniquement   |
| ► Notre approche (DL + XAI + MLOps)         | Minutes–heures | Très large, automatisée | Industrialisée et traçable |

Tableau 1.2 — Comparaison des méthodes d'évaluation des dégâts bâtiments

1.3.3 Benchmark des approches Deep Learning : identification du gap scientifique

Plusieurs travaux académiques et institutionnels ont proposé des architectures Deep Learning pour la classification des dégâts bâtiments sur images satellite. Le tableau suivant synthétise les approches les plus représentatives de l'état de l'art, avec leurs performances et surtout leurs limites du point de vue de l'explicabilité, de la reproductibilité et de l'industrialisation :

Tableau 1.3 — Benchmark des approches Deep Learning pour la classification de dégâts bâtiments

| Approche / Auteurs              | XAI             | MLOps      | Reprod. | Limite principale                                                  |
|---------------------------------|-----------------|------------|---------|--------------------------------------------------------------------|
| DeepDamageNet (arXiv, 2024)     | non             | non        | non     | Pas d'explicabilité ni de pipeline de déploiement                  |
| Braik et al. CACIE (2024)       | non             | non        | non     | Fine-tuning manuel, résultats non reproductibles                   |
| Cheng et al. AutoConstr. (2022) | non             | non        | non     | Classe Minor systématiquement sous-performante ; pas de monitoring |
| Ghasemi et al. — Sensors (2021) | SHAP            | non        | non     | XAI présent mais modèle non industrialisé                          |
| Prooijen et al. PMC (2023)      | Partiel CAM     | non        | non     | Pas de pipeline opérationnelle, non reproductible                  |
| ► Notre PFE (cible)             | Grad-CAM + SHAP | MLflow/DVC | Totale  | Outil industrialisé, traçable, prêt pour adaptation                |

La lecture de ce tableau fait apparaître avec clarté le gap scientifique que ce PFE vise à combler : **aucune des solutions publiées ne satisfait simultanément aux trois exigences d'un système opérationnellement viable** l'explicabilité des décisions (XAI), la traçabilité et la reproductibilité des expériences (MLOps), et l'industrialisation du cycle de vie du modèle (pipeline de déploiement et monitoring). Ce triple déficit est la raison fondamentale pour laquelle les modèles Deep Learning de BDA restent cantonnés au stade expérimental et ne sont pas adoptés dans les opérations réelles de gestion des catastrophes.

1.4 Contexte motivant : le Maroc, un territoire illustratif de l'urgence opérationnelle

Si les limitations identifiées dans la section précédente sont universelles, le territoire marocain offre une illustration particulièrement saisissante de leur coût opérationnel réel et constitue à ce titre la motivation géographique principale de ce PFE.

### 1.4.1 Un profil de risque inondatoire croissant

Le Maroc présente un profil de risque hydrique structurellement aggravé. Après sept années consécutives de sécheresse sévère, le pays a connu un basculement brutal : les réserves des barrages ont atteint **10 milliards de m<sup>3</sup>** au 2 février 2026, niveau inédit depuis 2018 (Médias24 / Pr. Fouad Amraoui, Université Hassan II, 2026). Ce paradoxe sols imperméabilisés par la sécheresse générant des crues éclair disproportionnées rend l'imprévisibilité des inondations marocaines particulièrement élevée. Sur le plan climatique, *World Weather Attribution* a établi que le réchauffement climatique a rendu les crues en Afrique du Nord environ **deux fois plus probables et 10 % plus intenses** qu'en contexte pré-industriel (2025).

### 1.4.2 Des crises récentes révélatrices du besoin opérationnel

La période 2024–2026 a concentré trois crises significatives au Maroc. En **septembre 2024**, dix-sept provinces du sud-est ont été affectées (170 mm/j à Tagounite, 18 décès, 110 routes endommagées). En **décembre 2025**, les crues de Safi ont causé 37 décès le bilan le plus lourd depuis plus d'une décennie. En **janvier–février 2026**, les inondations du Gharb ont contraint à l'évacuation de plus de 188 000 personnes, submergé 110 000 hectares agricoles et mobilisé un budget d'urgence gouvernemental de **3 milliards MAD (≈ 325 millions USD)** (Médias24 ; Atlas-mag ; CNDH, 2026).

Dans chacun de ces événements, l'évaluation des dégâts sur les bâtiments a reposé sur des moyens humains terrain, Forces armées royales et Protection civile sans outil automatisé de cartographie des dégâts par imagerie satellite. C'est précisément cette lacune que le système développé dans ce PFE ambitionne de combler à terme, **le Maroc étant identifié comme le premier territoire d'adaptation potentielle** de l'outil industrialisé produit dans ce travail.

## 1.5 Problématique du projet

L'analyse de l'existant conduit au constat suivant : les approches de Deep Learning pour la classification des dégâts bâtiments ont atteint des niveaux de performance prometteurs sur le plan de la précision brute. Cependant, elles partagent collectivement un **triple déficit ,opacité, non-reproductibilité, absence d'industrialisation** qui en fait des prototypes académiques inadaptés à un déploiement opérationnel réel. Aucun des travaux identifiés ne livre un système à la fois explicable, traçable et prêt à être maintenu en production.

*Comment concevoir et développer un système de classification automatique des dégâts bâtiments en 4 classes à partir d'images satellites, qui soit à la fois performant (Deep Learning bi-temporel entraîné sur xBD), interprétable pour les décideurs (XAI : Grad-CAM, SHAP), et industrialisé dans une pipeline MLOps garantissant la traçabilité, la reproductibilité et le monitoring, de façon à livrer un outil documenté et modulaire, prêt à être adapté à de nouveaux contextes opérationnels ?*

## 1.6 Objectifs du projet

### 1.6.1 Objectif général

Concevoir, développer et valider un système industrialisé de classification automatique des dégâts bâtiments en 4 classes à partir d'images satellites, intégrant Deep Learning, explicabilité XAI et pipeline MLOps, et livrer un outil documenté et modulaire conçu pour être facilement adapté à de nouveaux contextes géographiques et événementiels.

### 1.6.2 Objectifs spécifiques et résultats attendus

|     | Objectif spécifique                                                                                                                             | Résultat attendu                                                                                                                                                 |
|-----|-------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| OS1 | Développer un modèle Deep Learning bi-temporel de classification des dégâts bâtiments en 4 classes (No Damage / Minor / Major / Destroyed)      | Modèle entraîné et évalué sur xBD                                                                                                                                |
| OS2 | Intégrer des techniques XAI (Grad-CAM, SHAP) pour rendre les prédictions du modèle interprétables et exploitables par des opérationnels         | Cartes d'activation pixel-level par classe et scores SHAP par canal spectral ; évaluation de la fidélité et stabilité des explications                           |
| OS3 | Mettre en place une pipeline MLOps garantissant la traçabilité, la reproductibilité et le monitoring continu du modèle                          | Pipeline opérationnelle : tracking des expériences (MLflow), versionnage des données et modèles (DVC), CI/CD (GitHub Actions), détection de drift (Evidently AI) |
| OS4 | Livrer un outil industrialisé, documenté et modulaire, conçu pour être facilement adapté à de nouveaux contextes géographiques et événementiels | Architecture modulaire découplée prête à être appliquée au contexte marocain dans une phase ultérieure                                                           |

### 1.6.3 Périmètre du projet et perspectives

Il est important de préciser le périmètre exact de ce PFE. L'ensemble des développements entraînement, évaluation, XAI, pipeline MLOps est conduit sur le dataset de référence **xBD** (Gupta et al., 2019), qui constitue le standard international pour la classification des dégâts bâtiments sur images satellite. Le système développé n'intégrera pas, dans le cadre de ce projet, de données d'imagerie satellite spécifiques au Maroc, faute de dataset annoté disponible pour ce territoire.

Cette contrainte est assumée et transformée en force : l'architecture modulaire et la pipeline MLOps conçues dans ce PFE sont **explicitement pensées pour faciliter un fine-tuning futur** sur des données marocaines crues du Gharb 2026, images VHR de Safi 2025 dès lors qu'un effort d'annotation sera réalisé. En ce sens, ce travail constitue une **étape fondatrice** : il livre les briques techniques, la documentation et les procédures sur lesquelles une adaptation opérationnelle au contexte marocain pourra s'appuyer directement.

---

## Références bibliographiques (Chapitre 1)

- [1] UNDRR. Global Assessment Report on Disaster Risk Reduction (GAR 2025). United Nations Office for Disaster Risk Reduction, 2025.
- [2] Munich Re / Statista. Insured flood losses worldwide, 2013–2023. Statista, 2024.
- [3] World Weather Attribution. Extreme weather and climate change attribution — North Africa. 2025.
- [4] Gupta R. et al. xBD: A Dataset for Assessing Building Damage from Satellite Imagery. arXiv:1911.09296, 2019.
- [5] Weber E. et al. DeepDamageNet: A two-step deep-learning model for multi-disaster building damage segmentation. arXiv:2405.04800, 2024.
- [6] Braik A. et al. Automated building damage assessment by integrating satellite imagery, GIS, and deep learning. Computer-Aided Civil and Infrastructure Engineering, 2024. DOI: 10.1111/mice.13197
- [7] Cheng J. et al. Building damage detection on extremely imbalanced datasets. Automation in Construction, 2022. DOI: 10.1016/j.autcon.2022.104330
- [8] Ghasemi M. et al. Earthquake-induced building damage mapping using XAI (SHAP). Sensors, 21(13), 4489, 2021. DOI: 10.3390/s21134489
- [9] Prooijen B.C. et al. Post-Disaster Damage Assessment Using Semi-Supervised Transformers. Remote Sensing, 15(20), 4920, 2023. DOI: 10.3390/rs15204920
- [10] Barrington L. et al. Crowdsourcing earthquake damage assessment (2012). Cité dans DeepDamageNet, arXiv:2405.04800, 2024.
- [11] World Bank / ImageCat. Post-Disaster BDA — 2010 Haiti Earthquake. GFDRR, 2010.
- [12] Selvaraju R.R. et al. Grad-CAM: Visual Explanations from Deep Networks. ICCV, 2017.
- [13] Lundberg S., Lee S. A Unified Approach to Interpreting Model Predictions (SHAP). NeurIPS, 30, 2017.
- [14] France24. Torrential floods in southeastern Morocco. Septembre 2024.
- [15] AFP / Space Daily. Flash flood kills 37 in Moroccan coastal town Safi. Décembre 2025.
- [16] Médias24 / Pr. Fouad Amraoui (Univ. Hassan II). État des barrages marocains. Février 2026.
- [17] Atlas-mag. Inondations Maroc — aide gouvernementale. Février 2026.
- [18] CNDH Maroc. Conclusions préliminaires sur la gestion des inondations, janvier–février 2026.